Redes Neuronales

Teoremas de Aproximación Universal

David Peña Peralta

October 2026

Exploración

1. Motivación
2. Historia
3. Introducción
4. Teorema de Cybenko
5. Demostración

Índice

1 Motivación

2 Historia

3 Introducción

4 Teorema de Cybenko

5 Demostración

IA

La Inteligencia Artificial es el fenómeno tecnológico más grande de estos años. Actualmente vemos como se ha apoderado de nuestra entorno digital.



Figure: La Inteligencia Artificial en el motor de búsqueda más conocido en el mundo.

Concepción

Primero, haremos una fuerte distinción. Inteligencia Artificial es el área de la computación que engloba este fenómeno. Lo que vemos en la Figura 1 es una herramienta que depende de un LLM (Large Lenguage Model)

Origen

La inteligencia Artificial como campo de investigación no es reciente. El LLM que mencionamos anteriormente es el resultado de años de trabajo e investigación. Pero, el origen de lo que actualmente llamamos IA puede resumirse en 2 palabras.

Origen

La inteligencia Artificial como campo de investigación no es reciente. El LLM que mencionamos anteriormente es el resultado de años de trabajo e investigación. Pero, el origen de lo que actualmente llamamos IA puede resumirse en 2 palabras.

Redes Neuronales.

Idea simplificada

Las redes neuronales, como su nombre indica, están inspirada en las neuronas del cerebro. Sin embargo, de momento las veremos como una función con nombre bonito.

$$A \to \mathfrak{m} \to B$$

El truco de magia

Las redes neuronales $\mathfrak{m}$ dentro de todo el conjunto de funciones tienen la siguiente propiedad.

Tan cerca como queramos

Tomamos una función f. Entonces, existe una red neuronal $\mathfrak{m}$ tal que

$$\mathfrak{m} \approx f.$$

La realidad

La magia viene con matices.

- La función f debe cumplir algunas propiedades.
- La red neuronal $\mathfrak{m}$ también.

Un problema común de la magia

Tengo una función f de interés, existe una red neuronal $\mathfrak{m}$ que se acerca a ella tanto como queramos. ¿Cómo la encontramos?

Encontrar $\mathfrak{m}$ pero para ello debemos aterrizar todo lo anterior

Índice

1 Motivación

2 Historia

3 Introducción

4 Teorema de Cybenko

5 Demostración

Índice

1 Motivación

2 Historia

3 Introducción

4 Teorema de Cybenko

5 Demostración

Una neurona

Para comenzar a sentar las bases de nuestra magia, que veremos que en realidad nunca fue magia. Expresaremos una neurona, a partir de la Figura **??**, como

$$\eta(\mathbf{x}) = f\left(\sum_{i=1}^{d} w_i x_i + b\right). \tag{1}$$

donde que $\mathbf{x} = (x_1, \ldots, x_d), x_i \in \mathbb{R}$ es un vector de d componentes, $w_i, b \in \mathbb{R}$ para cada i y f es una función denominada como función de activación.

Conjunto de neuronas

Notemos que si cambio los valores de w_i, b y/o la función f obtendremos distintas neuronas. Entonces cada neurona esta definida por un vector de pesos $\mathbf{w} = (w_1, \ldots, w_d)^\top$ y su bias $b \in \mathbb{R}$. Denotando el conjunto de parámetros de la neurona η con $\theta = (\mathbf{w}, b)$, definimos el conjunto de neuronas con función de activación f.

$$\mathcal{N}(f) = \left\{ \theta = (\mathbf{w}, b) \in \mathbb{R}^{d+1} : \eta(\mathbf{x}; \theta) = f\left(\sum_{i=1}^{d} w_i x_i + b \right) \right\}$$

Capas

A partir de la Figura **??**, vemos que una red neuronal se compone de capas. Una capa L es una conjunto de neuronas

$$L(f) = \{\eta(\cdot : \theta_n) \in \mathcal{N}(f) : n = 1, \ldots, N\}. \tag{2}$$

En una red neuronal de K capas existen 3 tipos.

- Capa de Entrada L_0
- Capas Ocultas $L_k, k = 1, \ldots, K-1$
- Capa de Salida L_K

Shallow Neural Networks

Para aplicar nuestro truco de magia requerimos que nuestra red neuronal tenga una sola capa oculta. Estas redes neuronales se conocen como Shallow Neural Networks y se representan de la siguiente forma

$$\mathfrak{m}(\mathbf{x};\Theta) = \sum_{i=1}^{N} c^n \eta(\mathbf{x},\theta_n), \tag{3}$$

donde $\Theta = \{(c^n,\theta_n)\}_{n=1}^{N}, \eta(\cdot,\theta) \in \mathcal{N}(f)$.

Deducción

Si una Shallow Neural Network posee una capa de entrada L_0 con d neuronas, entonces $\mathbf{x} = (x_1, \ldots, x_d)$. Estas al llegar a la capa oculta L_1 con N neuronas, veremos que cada neurona obtendrá

$$\eta(\mathbf{x}, \theta_n) = f(\mathbf{w}^n \cdot \mathbf{x} + b^n),$$

con $\theta_n = (\mathbf{w}^n, b^n), n = 1, \ldots, N$. Al final, al llegar la capa de salida L_2 con $\mathbf{x}_1 = (x_1^1, \ldots, x_1^N)$ y $x_1^i = \eta(\mathbf{x}, \theta_i), i = 1, \ldots, N$ obtenemos que

$$\sum_{n=1}^{N} c^n x_1^n = \sum_{i=1}^{N} c^n \eta(\mathbf{x}, \theta_n) = \mathfrak{m}(\mathbf{x}; \Theta),$$

con $\Theta = \{(c^n, \theta_n)\}_{n=1}^N$

Función de Activación

La función de activación es otra parte importante para que la magia funcione. Pero requiere de nuestra participación. Cada capa L define la función de activación desde antes que comience la magia. Esto quiere decir que en las Shallow Neural Network cada función de activación f define un pequeño de truco de magia distinto.

Función Sigmoidal

En esta ocasión veremos la magia proveniente de las funciones de tipo sigmoidal.

Función Sigmoidal

Sea $\sigma : \mathbb{R} \to \mathbb{R}$. Diremos que σ es una función sigmoidal si

$$\lim_{x \to \infty} \sigma(x) = 1, \lim_{x \to -\infty} \sigma(x) = 0.$$

Considere como ejemplo tipico la función sigmoide

$$\sigma(x) = \frac{e^x}{1 + e^x} = \frac{1}{1 + e^{-x}}$$

Con todo lo anterior, definiremos las Shallow Neural Networks que usaremos para mostrar el truco de magia.

$$\mathfrak{m}(\mathbf{x};\Theta) = \sum_{i=1}^{N} c^n \sigma(\mathbf{w}^n \cdot \mathbf{x} + b^n), \tag{4}$$

donde $\Theta = \{(c^n, \mathbf{w}^n, b^n)\}_{n=1}^{N}$. Notemos que la única diferencia con (3) es que $\eta(\cdot, \theta_n) \in \mathcal{N}(\sigma)$.

La realidad

Ya veníamos adelantando que esto no es magia. Es un resultado demostrado hace más de 30 años. Pero si lo fuera, el truco tiene nombre y es Teorema de Cybenko.

Índice

1 Motivación

2 Historia

3 Introducción

4 Teorema de Cybenko

5 Demostración

Teorema Cybenko [1989]

Sea $I_d = [0,1]^d$ y $C(I_d)$ el conjunto de funciones continuas en I_d.

Teorema de Cybenko

Sea σ una función sigmoidal continua. Entonces las sumas finitas de la forma (4) son densas en $C(I_d)$, donde $I_d = [0,1]^d$

El Teorema nos dice que para cualquier función continua f y $\epsilon > 0$ puedo encontrar una Shallow Neural Network $\mathfrak{m}$ con parámetro Θ^* tal que

$$|\mathfrak{m}(\mathbf{x}, \Theta^*) - f(\mathbf{x})| < \epsilon$$

Preliminares

Conjunto Denso

Sea X un espacio normado y D un subconjunto de X. Diremos que D es denso en X si

$$\overline{D} = X \tag{5}$$

Función Discriminatoria

Considere $\mu \in \mathcal{M}(I_d)$ y una función $\sigma : \mathbb{R} \to \mathbb{R}$. Entonces σ es una función discriminatoria con respecto a la medida μ si

$$\int_{I_d} \sigma(\mathbf{w} \cdot \mathbf{x} + b)\mu(\mathrm{d}x) = 0 \tag{6}$$

para cada $(\mathbf{w}.b) \in \mathbb{R}^{d+1}$ implica que $\mu \equiv 0_{\mathcal{M}(I_d)}$

Índice

1 Motivación

2 Historia

3 Introducción

4 Teorema de Cybenko

5 Demostración

Consideraciones

Importante resaltar lo siguiente

- Presentaremos un bosquejo de la prueba.
- La prueba esta basada en Spiliopoulos et al. [2025]
- La prueba completa requiere bibliografía adicional.

Lema

Para la demostración requeriremos el siguiente Lema.

Proposición 16.3 Spiliopoulos et al. [2025]

Sea σ una función sigmoidal continua. Entonces σ es una función discrimatoria con respecto a todas las medidas $\mu \in \mathcal{M}(I_d)$.

Conjunto a verificar

Definimos el conjunto U como

$$U = \left\{ \mathfrak{m}(\cdot, \Theta); N \in \mathbb{N}, \Theta \in \mathbb{R}^{(d+2)N} \middle| \mathfrak{m}(\mathbf{x}; \Theta) = \sum_{i=1}^{N} c^n \sigma(\mathbf{w}^n \cdot \mathbf{x} + b^n) \right\}, \tag{7}$$

Probando que U es un subespacio de $C(I_d))$, queda probar que $\overline{U} = C(I_d)$.

Bosquejo

La demostración es una prueba por contradicción.

- Suponemos que $\overline{U} \neq C(I_d)$. Entonces existe $q \in C(I_d)$ tal que $q \in C(I_d) - \overline{U}$.
- Usando q podemos construir un funcional lineal $h : \overline{U} \to \mathbb{R}$ tal que $h(u) = 0, \forall u \in \overline{U}$ y $h(q) \neq 0$.
- Por el Teorema de Hahn Banach. Existe un funcional lineal $f : C(I_d) \to \mathbb{R}$ tal que $f(u) = h(u) = 0, \forall u \in \overline{U}$ y $f(q) \neq 0$.

- Usando el Teorema de Riesz-Markov. Existe una medida $\mu \in \mathcal{M}(I_d)$ tal que

$$f(u) = \int_{I_d} u\mu(\mathrm{d}x), \forall u \in C(I_d).$$

- Por definición de $\overline{U}$, tenemos que $\sigma(\mathbf{w} \cdot \mathbf{x} + b) \in \overline{U}$ para cada $(\mathbf{w}, b) \in \mathbb{R}^{d+1}$. Por el punto anterior y la construcción de f.

$$\int_{I_d} \sigma(\mathbf{w} \cdot \mathbf{x} + b)\mu(\mathrm{d}x) = f(\sigma(\mathbf{w} \cdot \mathbf{x} + b)) = 0, \forall (\mathbf{w}, b) \in \mathbb{R}^{d+1}$$

- Por el Lema 28, σ es una función discriminatoria. Entonces el punto anterior implica que $\mu \equiv 0_{\mathcal{M}}(I_d)$.

Contradicción

Pero $\mu \equiv 0_{\mathcal{M}_{I_d}}$ lleva una contradicción. Esto porque el Teorema de Riesz-Markov implica que $f \equiv 0$. Pero existe un punto q tal que $f(q) \neq 0$. Por lo tanto, U es denso y $\overline{U} = C(I_d)$.

Bibliografia I

G. Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals, and Systems*, 2:303–314, 12 1989. ISSN 0932-4194. doi: 10.1007/BF02551274. URL `http://link.springer.com/10.1007/BF02551274`.

Konstantinos Spiliopoulos, Richard Sowers, and Justin Sirignano. *Mathematical Foundations of Deep Learning Models and Algorithms*. American Mathematical Society, 2025. `MathDL.github.io`.